

Problem Chosen

2026

Team Control Number

C

MCM

Summary Sheet

123456

DWTS 淘汰机制的可复现推断与赛制设计

摘要

我们基于题面给定的 DWTS 官方赛季周度数据表，构建了一条端到端、可复现的建模流水线。该流水线先将原始宽表规范化为两张主线数据集（周度面板与赛季特征），再在统一口径下生成可追溯的 CSV/PDF 产物并落盘至 `outputs/` 目录，保证“论文叙述—模型输入—图表证据”一致。在数据口径层面，周度面板 `data/processed/dwts_weekly_panel.csv` 与赛季特征 `data/processed/dwts_season_features.csv` 的整体缺失率分别为 **4.54%** 与 **2.42%**（以空值/NaN 占全表单元格比例计），为后续 Q1–Q4 提供了稳定、可审计的输入边界。

问题 1：我们将观众投票视为不可观测潜变量，在每个 `season×week` 上利用淘汰/退赛结果与评委信号进行约束，推断周内相对观众份额的后验分布。核心产物为后验汇总表 `outputs/predictions/mcm2026c_q1_fan_vote_posterior_summary.csv` 与不确定性诊断表 `outputs/tables/mcm2026c_q1_uncertainty_summary.csv`，并配套生成可直接用于论文的矢量图。在 Percent 机制口径下，Q1 覆盖 **335** 个赛季-周点（其中 **266** 周存在淘汰/退赛约束），有效样本量占比（ESS ratio）的均值为 **0.627**、第 10 百分位为 **0.404**；证据强度（evidence）的均值为 **0.320**、第 10 百分位为 **0.069**，用于识别“低可识别/高风险周”并支撑后续反事实核查。

问题 2：我们在 Q1 后验输出基础上，对 Percent 与 Rank 两类投票汇总机制进行反事实对比，量化机制差异在赛季与周尺度的分布，并定位“高分歧周/赛季”。赛季层汇总结果写入 `outputs/tables/mcm2026c_q2_mechanism_comparison.csv`，并辅以可视化诊断图支持逐周核查。在 34 个赛季的对比中，有 **22** 个赛季出现 Percent 与 Rank 的淘汰差异周（`diff_weeks_percent_vs_rank>0`），差异周数的中位数为 **1**、最大值为 **5**，用于证明“机制差异并非仅由极端个例驱动”。

问题 3：我们在同一数据口径下将比赛表现分解为评委线（技术表现）与观众线（人气强度），并拟合可解释的混合效应/OLS 模型以分析年龄、行业、地区、舞伴等因素的影响方向与区间。关键系数与置信区间汇总于 `outputs/tables/mcm2026c_q3_impact_analysis_coeffs.`

问题 4：我们在受控压力测试下评估多种新赛制候选机制（多档离群冲击强度），并同时报告技术保护、公平性、人气表达与鲁棒性等多目标指标。主线指标产物为 `outputs/tables/mcm2026c_q4_new_system_metrics.csv`，并通过决策视图图表将多目标权衡转化为可执行的机制建议。在主线设定 `alpha=0.5`、`sigma_scale=2.0` 与压力强度 `outlier_mult∈{2, 5, 10}` 下，推荐机制汇总表 `outputs/tables/paper_q4_recommendation_summ` 给出一致的推荐：**Rank** 机制的技术保护（TPI）均值为 **0.849**（95% 区间 [0.829, 0.869]），观众表达（Fan）均值为 **0.393**（95% 区间 [0.335, 0.451]）；其鲁棒性失效率（Fail）在三档压力下分别为 **0.440/0.456/0.460**，用于量化“离群动员”对制度稳定性的影响幅度。

Keywords: DWTS, latent fan vote inference, counterfactual mechanism evaluation, mixed-effects interpretability, robustness stress tests

目录

1	Introduction	4
1.1	Background	4
1.2	Restatement of the Problem	4
1.3	Our Work	4
2	Problem Analysis	6
2.1	Analysis of Question One	6
2.2	Analysis of Question Two	6
2.3	Analysis of Question Three	7
2.4	Analysis of Question Four	7
3	Assumptions and Justifications	9
4	Notations	9
5	Data Preprocessing	10
5.1	Data sources and canonicalization	10
5.2	Q0 canonicalization details (implementation-aligned)	10
5.3	Feature construction for downstream tasks	10
5.4	Reproducibility and audit artifacts	11
6	Model Building and Solution	13
6.1	Model Establishment and Solution of Question One	13
6.1.1	Model Establishment	13
6.1.2	Inference mechanics (aligned to implementation)	13
6.1.3	Results	14
6.2	Model Establishment and Solution of Question Two	15
6.3	Model Establishment and Solution of Question Three	16
6.4	Model Establishment and Solution of Question Four	18
7	Sensitivity Analysis and Error Analysis	20
7.1	Sensitivity Analysis	20
7.2	Error Analysis for Question 1	23
7.3	Error Analysis for Question 2	25
8	Model Evaluation	27
8.1	Advantages of the Model	27
8.2	Disadvantages of the Model	27
8.3	Key visual evidence	28

8.4	Artifact and evidence index (mainline)	30
8.5	Claim-to-evidence mapping	32
8.6	Q4 recommendation summary (reproducible)	32
9	Conclusion	33
	References	35
	Report on Use of AI	36

1 Introduction

1.1 Background

DWTS (Dancing with the Stars) 以“评委打分 + 观众投票”的方式决定每周淘汰，但题面数据并未直接给出真实投票数/投票比例。工程上，这使得“观众偏好 (fan preference)”成为一个 **不可观测的潜变量**：它对淘汰结果有影响，却没有被直接记录。

本题的难点并不在于把一个复杂模型写出来，而在于如何在信息不完全的条件下建立 **可复核、可再生、可追溯** 的推断与决策链路：(1) 用统一数据口径把原始宽表加工为稳定的周度面板；(2) 用淘汰结果与评委信号约束出观众偏好强度的后验区间；(3) 在此基础上对不同投票汇总机制进行反事实对比；(4) 进一步分析影响因素并提出新机制，同时用压力测试保证结论对极端情形不脆弱。

因此，我们将整套解题过程实现为端到端流水线：从原始 DWTS 数据到 `outputs/` 目录下的 CSV/PDF 证据文件，都可以通过一次运行确定性再生（见 `run_all.py`）。

1.2 Restatement of the Problem

1. **Q1 (观众投票反推)**：在缺少真实投票数据的条件下，利用每周淘汰/退赛结果与评委信号，推断周内选手的相对观众支持强度，并给出不确定性度量。
2. **Q2 (机制对比/反事实)**：对比 Percent 与 Rank 两类投票汇总机制（及 Judge Save 变体），量化其在周尺度与赛季尺度对淘汰结果的影响与分歧来源。
3. **Q3 (因素影响)**：将“评委线（技术表现）”与“观众线（人气强度）”分离建模，分析年龄、行业、地区、舞伴等因素在两条线上的作用方向与区间，并检验稳定性。
4. **Q4 (新机制设计与评估)**：提出并评估可执行的新赛制机制，在公平性（技术保护）、娱乐性（观众表达）与鲁棒性（压力测试）等多目标下给出推荐与解释。

1.3 Our Work

我们的工作强调“论文叙述—代码实现—产物证据”一致，具体包括：

(1) **统一数据口径(Q0)** 我们将题面 DWTS 宽表转换为两张主线数据集：`data/processed/dwts_week`（周度面板）与 `data/processed/dwts_season_features.csv`（赛季特征），并输出审计表 `outputs/tables/mcm2026c_q0_sanity_*.csv` 用于复核。

(2) **观众偏好后验与诊断(Q1)** 在每个 `season×week` 上，我们对观众份额 (simplex) 进行后验抽样并输出区间，核心证据为：`outputs/predictions/mcm2026c_q1_fan_vote_posterior_summ`

(后验汇总)与 `outputs/tables/mcm2026c_q1_uncertainty_summary.csv` (不确定性诊断), 并配套生成 PDF 图.

(3) 反事实机制对比(Q2) 在 Q1 输出的基础上,我们对 Percent/Rank 及 Judge Save 变体进行周级与赛季级对比,形成 `outputs/tables/mcm2026c_q2_mechanism_comparison.csv` 与周级复核表.

(4) 可解释影响因素与新机制评估 (Q3–Q4) Q3 用混合效应/OLS 报告可解释系数区间; Q4 在多档压力强度下评估候选机制并输出多目标指标与决策故事板.

(5) 一键再生与论文证据导出 主线入口为 `run_all.py`, 默认依次运行 Q0–Q4 并导出 `paper_*.csv` (由 `src/mcm2026/pipelines/mcm2026c_export_paper_tables.py` 从主表确定性裁剪得到), 保证论文表格可复现.

Stage	Main script (repo path)	Primary outputs
Q0	<code>src/mcm2026/pipelines/mcm2026c_q0_build_weekly_data_processed/*.csv</code>	<code>by_app/processed/*.csv</code>
Q1	<code>src/mcm2026/pipelines/mcm2026c_q1_smc_fan_vote.py</code>	<code>outputs/predictions/*.csv</code>
Q2	<code>src/mcm2026/pipelines/mcm2026c_q2_counterfactuals.py</code>	<code>outputs/tables/mcm2026c_q2_*</code>
Q3	<code>src/mcm2026/pipelines/mcm2026c_q3_mixed_effect_ols.py</code>	<code>outputs/tables/mcm2026c_q3_*</code>
Q4	<code>src/mcm2026/pipelines/mcm2026c_q4_design_space.py</code>	<code>outputs/tables/mcm2026c_q4_*</code>

表 1: 工程化 workflow 概览: 从脚本到产物的最短可追溯路径 (更完整映射见 Sec. 7 的 Artifact Index)。

2 Problem Analysis

2.1 Analysis of Question One

Q1 的核心是一个 **逆问题 (inverse problem)**: 观众投票不可观测, 但淘汰结果可观测。我们需要从“可观测结果”反推“潜在偏好强度”。

Observed signals 题面提供的可观测信号主要包括: (1) 每周每位选手的评委总分与由此构造的 `judge_score_pct/ judge_rank`(技术线);(2) 每周淘汰/退赛标记 `eliminated_this_week/ withdrew_this_week` (结果线)。

Latent target 我们希望得到每个 `season×week` 内选手的相对观众份额 (`simplex`): `fan_share` 以及其跨周可比较的指数形式 `fan_vote_index`。

Identifiability and uncertainty 由于缺少真实票数, Q1 输出只能解释为 周内相对强度。当周在场人数少、当周退出人数多、或评委排序与淘汰结果高度矛盾时, 约束信息量下降, 后验会更不稳定。因此我们必须同步输出不确定性诊断 (如 `ess_ratio` 与 `evidence`), 并在论文中明确指出“高风险周段”。

Engineering outputs (evidence) Q1 的主证据文件为: `outputs/predictions/mcm2026c_q1_fan_v` (后验均值/分位数) 与 `outputs/tables/mcm2026c_q1_uncertainty_summary.csv` (诊断汇总), 并通过图 2 与图 8 将“区间 + 可识别性”可视化。

2.2 Analysis of Question Two

Q2 是一个 **反事实评估 (counterfactual evaluation)** 问题: 在固定同一赛季-周背景条件下, 仅替换“合成得分”的规则, 观察淘汰集合是否改变。

Key design choice Percent 与 Rank 的差异可理解为: (1) Percent 保留幅度信息 (差距大小会影响合成得分); (2) Rank 只保留相对次序 (幅度被压缩)。在现实 DWTS 中, 两者都可能被使用或混用, 因此我们将其作为两条候选机制进行并行对比。

Failure modes to control Q2 的工程风险主要有两类: (1) **上游缺失传播**: Q1 若出现缺失或极端不确定性, 会导致某些周的 `fan_share` 不可用。我们在实现中将缺失回退到均匀分布, 并在赛季级汇总中记录 `missing_fan_share_week_rate` 与 `missing_fan_share_total`, 避免“静默失败”。(2) **退出定义差异**: 退赛是否应计为“离开节目”会影响评估口径, 因此该开关由 `dwts.q2.count_withdraw_as_exit` 控制, 并在输出表中显式记录。

Engineering outputs (evidence) Q2 提供三层证据:(1) 赛季级汇总 `outputs/tables/mcm2026c_q2` (含 `diff_weeks_percent_vs_rank`、匹配率与缺失统计);(2) 周级复核 `outputs/tables/mcm2026c_q2` 与 `outputs/tables/mcm2026c_q2_week_level_comparison_rank.csv`; (3) 图证: 周层分歧定位 (图 3) 与差异分布 (图 4)。

2.3 Analysis of Question Three

Q3 的目标不是“预测冠军”，而是回答“哪些因素分别影响技术线与人气线”。因此我们将任务拆成两条可解释回归: (1) 评委线因变量: 赛季级 `judge_score_pct_mean`; (2) 观众线因变量: 赛季级 `fan_vote_index_mean`。

Why season-level 题面提供的是周度面板，但解释变量多为赛季静态属性（年龄、行业、州/国家、舞伴）。将周度信号聚合到赛季级别可以减少噪声，并使协变量含义更稳定。

Uncertainty propagation (engineering requirement) 观众线因变量来自 Q1 推断，因此必须传播不确定性。我们用 Q1 的 `p05/p95` 近似每周不确定性并聚合为赛季均值的不确定度，再进行 `n_refits` 次重拟合，输出系数区间并给出“符号一致性/区间宽度”等稳定性诊断。

Engineering outputs (evidence) Q3 的主证据为 `outputs/tables/mcm2026c_q3_impact_analysis` 配套的可复核证据包括: `outputs/tables/mcm2026c_q3_fan_refit_coeff_draws.csv` 与 `outputs/tables/mcm2026c_q3_fan_refit_stability.csv` (不确定性传播与稳定性)。图证包含系数森林图 (图 5) 与非线性年龄效应 (图 6)。

2.4 Analysis of Question Four

Q4 是一个 **机制设计与评估 (mechanism design + evaluation)** 问题。我们不尝试“还原现实的真实冠军”，而是在 Q1 可识别的偏好空间内，比较不同机制在三类目标上的权衡: (1) **技术保护**: 冠军在整个赛季的评委百分位表现 (`TPI`); (2) **观众表达**: 观众份额分布相对均匀分布的差异 (`fan-vs-uniform contrast`); (3) **鲁棒性**: 在压力测试 (多档 `outlier_mult`) 与扩展攻击策略下的失效概率。

Why stress tests 现实中存在“外部动员型”极端案例 (题面也暗示争议赛季)。如果只在历史常态下评估机制，结论可能对极端情形脆弱。因此我们将离群冲击作为受控压力测试: 并非预测真实概率，而是用于比较“机制抗压能力”的相对强弱。

Engineering outputs (evidence) Q4 主表为 `outputs/tables/mcm2026c_q4_new_system_metrics` 其中包含 `champion_entropy`、`tpi_season_avg`、`fan_vs_uniform_contrast` 与多种 `robust_fail_rate` 列。为了将主表收敛为论文可读的结论,我们额外生成汇总表 `outputs/tables/mcm2026c_q4_sensitivity` 与 `paper_q4_recommendation_summary.csv` (确定性裁剪)。

图证包含: 多目标权衡散点图 (图 15)、鲁棒性曲线 (图 13)、冠军不确定性故事板 (图 14) 与机制选择指南 (图 16)。

3 Assumptions and Justifications

- 为便于将题面问题转化为可计算、可复核的工程化流程，我们提出如下假设：
- 假设 1：

题面提供的 DWTS 官方数据表在 Q0 预处理后可视为内部一致；由 `season` $\times$ `week` $\times$ `contestant` 构成的键是 Q1–Q4 的唯一主线口径。
- 假设 2：

Q0 提取的淘汰/退赛标记能够正确识别当周退出选手集合；退出后的缺失分数不做插补，以避免引入未来信息。
- 假设 3：

观众投票不可直接观测；Q1 将观众偏好作为潜变量，并由退出结果与评委信号共同约束。因此 Q1 输出解释为周内相对人气强度，而非绝对票数。
- 假设 4：

在 Q2–Q4 评估替代机制时，我们固定赛季-周背景，并将 Q1 推断得到的观众强度后验视为可行偏好空间；不额外建模规则变化诱发的策略性行为改变。
- 假设 5：

`src/mcm2026/config/config.yaml` 中的配置参数（如 `alpha`, `tau`, `outlier_mults`）体现制作方偏好与压力强度设定；鲁棒性结论均在这些设定条件下报告。

4 Notations

Symbol	Description	Symbol	Description
s	赛季索引	t	赛季内周索引
i	选手（celebrity）索引	$J_{s,t,i}$	评委信号（例如 <code>judge_score_pct</code> ）
$p_{s,t,i}$	观众份额（Q1 后验汇总）	α	机制中评委-观众权重
τ	Q1 软约束温度	ESS ratio	有效样本量占比（Q1 不确定性）

注：未定义的符号将在首次出现处给出定义。

5 Data Preprocessing

本研究仅使用题目给定的 DWTS 官方赛季周度数据表。为确保后续推断（Q1）与机制对比/仿真（Q2–Q4）在同一数据口径下进行，我们首先将原始宽表转换为“周度面板（weekly panel）+ 赛季层特征（season features）”两张规范化数据集，并进行一致的缺失与异常处理。

5.1 Data sources and canonicalization

- (1) **字段解析与类型规范化**：将赛季 $\times$ 周 $\times$ 选手作为唯一键，统一数值字段（评委分、周平均分等）的类型；对字符串字段（选手名、机制名等）去除多余空格并标准化。
- (2) **缺失与退出处理**：对明确“退出/退赛/淘汰”的记录在周度面板中标注退出周；对后续周的缺失分数不做插补（避免引入未来信息），仅用于“在场/不在场”状态更新。
- (3) **一致性检查**：对每周在场人数、淘汰人数、分数范围进行基础审计，保证不存在明显的逻辑冲突（例如同一周多次淘汰、在场选手分数缺失占比异常等）。

5.2 Q0 canonicalization details (implementation-aligned)

Q0 主线脚本 `src/mcm2026/pipelines/mcm2026c_q0_build_weekly_panel.py` 将官方宽表中的周-评委打分行（形如 `weekX_judgeY_score`）解析为长表，并对每位选手在每周的评委分求和得到 `judge_score_total`。随后在每个 `season $\times$ week` 内计算评委分占比 `judge_score_pct`（保证在场选手占比和约为 1），并给出评委名次 `judge_rank`（1 为最好）。

在场状态 `active_flag` 由当周 `judge_score_total` > 0 判定；退出推断依赖题面 `results` 文本字段：(1) 若 `results` 包含 `Eliminated` 或 `Withdrew` 则提取退出类型；(2) 若能解析出 Week k ，则记为 `elimination_week`；(3) 若退出周无法解析或与最后一次出场周不一致，则回退为 `last_active_week` 得到 `exit_week_inferred`。该逻辑保证后续 Q1–Q4 使用的退出标记只依赖历史周信息，不引入未来信息。

为便于快速复核，Q0 同时输出周级与选手级审计表（见 `mcm2026c_q0_sanity_season_week.csv` 与 `mcm2026c_q0_sanity_contestant.csv`），其中包含 `pct_sum_active`（应接近 1）与退出标记计数等不变量，用于在论文阶段快速排除数据口径错误。

5.3 Feature construction for downstream tasks

在周度面板中，我们构造了以下关键特征（在 Q1–Q4 反复使用）：

- (1) **评委维度**：当周评委总分与其在当周的百分位/名次（用于“评委信号”）。
- (2) **观众维度（可观测代理）**：由当周淘汰结果与评委信号共同约束，形成观众偏好强度的可推断结构（用于 Q1 的后验推断与不确定性量化）。
- (3) **机制相关指标**：针对 Percent 与 Rank 两种投票合成方式，构造每周的机制得分、相对差异、以及跨周可比较的度量。

为直观展示数据结构与“评委信号—观众结果”之间的关系，我们给出评委分与观众偏好推断信号的散点示意（图1）。该图既是数据探索的入口，也用于验证后续模型的方向性是否符合常识（例如评委分高但仍被淘汰的周，往往对应更强的观众偏好差异）。




图 1: 数据结构示意：评委分与观众偏好信号的关系（用于后续 Q1 推断与诊断）。

5.4 Reproducibility and audit artifacts

为保证“论文叙述—模型输入—输出图表”三者一致，我们在 Q0 阶段将原始 DWTS 宽表转换为两张规范化主线数据集，并提供对应的审计表用于快速核对。

Canonical processed datasets (Q0 outputs)

- (1) `../data/processed/dwts_weekly_panel.csv`: 周度面板 (2777×18)。该表包含后续 Q1–Q4 所需的核心字段：`judge_score_total`, `judge_score_pct`, `judge_rank`, `active_flag`（以上核心字段缺失为 0）。
- (2) `../data/processed/dwts_season_features.csv`: 赛季层特征 (421×11)。该表提供静态协变量（年龄、行业、地区、舞伴等）用于 Q3 解释模型。

Missingness and exit-type sanity checks 基于主线 processed 数据表的统计审计：周度面板整体缺失率约为 **4.54%**，赛季特征表整体缺失率约为 **2.42%**；按选手赛季结果推断的退出类型分布为 `eliminated=298, withdrew=10, unknown=113`。这些统计用于约束后续推断的“信息量”与边界条件（例如多退出周、退赛周等）。

Q0 audit tables (written under outputs/tables/)

- (1) `../outputs/tables/mcm2026c_q0_sanity_season_week.csv`: 逐赛季逐周审计（在场人数、淘汰/退赛标记、分数百分位和等）。
- (2) `../outputs/tables/mcm2026c_q0_sanity_contestant.csv`: 逐选手审计（淘汰周/退赛周推断与一致性检查）。

6 Model Building and Solution

6.1 Model Establishment and Solution of Question One

6.1.1 Model Establishment

Q1 的目标是在题面未直接给出投票数/投票比例的条件下，为每个赛季-周-选手构造可用于后续机制对比的“观众偏好强度”后验分布。我们将周淘汰结果视为对观众偏好的一条弱监督约束，将评委信号作为技术线参考，并在每个 `season×week` 上独立地推断一组粉丝份额（simplex）并量化不确定性。

6.1.2 Inference mechanics (aligned to implementation)

在实现上，我们对每个 `season×week` 独立进行一次重要性抽样：

Step 1: prior draw (fan simplex) 对当周在场选手集合（大小为 n ），从对称 Dirichlet 先验抽样得到 M 组候选观众份额向量：

$$\mathbf{p}^{(m)} \sim \text{Dirichlet}(\mathbf{1}), \quad m = 1, \dots, M. \quad (1)$$

Step 2: combine judge and fan signals Percent 机制下，我们将评委百分比 J_i 与候选观众份额 p_i 线性合成：

$$S_i^{(m)} = \alpha J_i + (1 - \alpha) p_i^{(m)}. \quad (2)$$

Rank 机制下，我们将评委排名与粉丝排名线性合成得到 $R_i^{(m)}$ （实现中粉丝排名由 $p^{(m)}$ 排序得到）。

Step 3: soft elimination likelihood 将“淘汰者应更可能来自合成得分较差的选手”写成软约束：

$$\Pr(\text{exit} = i \mid \mathbf{p}^{(m)}) \propto \exp\left(\frac{-S_i^{(m)}}{\tau}\right) \quad (\text{Percent}). \quad (3)$$

Rank 机制下对应地使用 $R_i^{(m)}/\tau$ 进入 softmax。对于当周观测到的退出集合（可能为多退出），实现中按“无放回抽取”的集合概率计算似然，并以此对样本加权。

Step 4: posterior reweighting and diagnostics 记第 m 个样本的集合似然为 $\ell^{(m)}$ ，则重要性权重为 $w^{(m)} \propto \ell^{(m)}$ 。我们同时输出三个关键诊断量：(1) **Evidence**: $\mathbb{E}[\ell]$ （实现为 $\text{mean}(\ell)$ ）；(2) **ESS ratio**: ESS/M （ $\text{ESS} = 1/\sum_m (\tilde{w}^{(m)})^2$ ）；(3) 对 M 个样本按 w 重采样 R 次得到后验样本，并据此输出 `mean/median/p05/p95` 区间。

Fan vote index 为便于跨周比较，观众份额同时映射为指数形式（实现为 logit 变换）：

$$\text{fan_vote_index} = \log \frac{p}{1-p}. \quad (4)$$

Inputs (canonical)

- (1) data/processed/dwts_weekly_panel.csv (Q0 输出): 包含 active_flag、eliminated_this_week、withdrew_this_week、judge_score_pct、judge_rank 等。
- (2) src/mcm2026/config/config.yaml: 读取 dwts.q1.alpha, dwts.q1.tau, dwts.q1.prior_draws, dwts.q1.posterior_resample_r。

Outputs (mainline artifacts)

- (1) outputs/predictions/mcm2026c_q1_fan_vote_posterior_summary.csv: 每周每位选手的 fan_share_mean/median/p05/p95 与 fan_vote_index_mean/median/p05/p95 (Percent 与 Rank 两套机制各一份)。
- (2) outputs/tables/mcm2026c_q1_uncertainty_summary.csv: 每周不确定性诊断 (ess_ratio, evidence 等)。

6.1.3 Results

图2展示了 Q1 的核心输出：在每个赛季-周内，以后验区间呈现选手的相对观众份额，并标注不确定性差异。该后验汇总表是 Q2（反事实机制对比）与 Q4（新机制压力测试/设计评估）的直接上游输入。




图 2: Q1 核心输出示意：观众份额后验区间（用于支撑后续机制对比与仿真）。

6.2 Model Establishment and Solution of Question Two

Q2 在 Q1 后验输出的基础上，进一步回答“投票汇总机制改变会如何改变淘汰结果”。我们将观众端信号在 Percent 与 Rank 两类机制下进行对照，并用两张图把差异从“定位（哪一周最分歧）”与“分布（差异是系统性还是偶发）”两条视角串联起来。

Counterfactual rule implementation 在每个 `season×week` 上，令当周需要退出的人数为 k （由 `eliminated_this_week` 与 `count_withdraw_as_exit` 共同确定）。Percent 机制下合成得分与预测退出集合为：

$$S_i = \alpha J_i + (1 - \alpha) \hat{p}_i, \quad \hat{\mathcal{E}}_{\text{percent}} = \operatorname{argmin}_{|\mathcal{E}|=k} S_i. \quad (5)$$

Rank 机制下合成排名为：

$$R_i = \alpha \operatorname{rank}(J_i) + (1 - \alpha) \operatorname{rank}(\hat{p}_i), \quad \hat{\mathcal{E}}_{\text{rank}} = \operatorname{argmax}_{|\mathcal{E}|=k} R_i. \quad (6)$$

为避免上游缺失导致静默失败，若 Q1 在当周某些选手的 `fan_share_mean` 缺失，实现会回退到均匀分布并在输出中记录缺失统计。

Judge Save variant 当 $k = 1$ 时，我们额外实现 Judge Save 变体：先按 Percent/Rank 得到 `bottom2`，再由评委分（`judge_score_total`）决定淘汰其中技术更差者。

Inputs/Outputs (mainline artifacts) Q2 直接读取 `outputs/predictions/mcm2026c_q1_fan_vo` 并写出 `outputs/tables/mcm2026c_q2_mechanism_comparison.csv` 作为赛季层对比汇总（含 `diff_weeks_percent_vs_rank` 与各类匹配率）。周层比较明细在 `outputs/tables/mcm2026c_q2_week_level_comparison_rank.csv` 中，可用于逐周复核。




图 3: Q2 周层分歧定位 (Model Building 视角): 识别 Percent 与 Rank 在何时产生最大分歧, 为反事实模拟提供切入点。




图 4: Q2 机制差异分布 (Model Building 视角): 检验差异是否集中在少数极端周, 避免仅凭个例下结论。

6.3 Model Establishment and Solution of Question Three

Q3 旨在回答“哪些因素驱动选手在评委线 (technical) 与观众线 (fan) 上的相对优势”。我们在同一数据口径下分别对两条信号建模, 并用可解释的系数比较来呈现不同因素的方向与大小。

Two-line modeling strategy 实现中我们构造赛季级数据集：(1) 技术线因变量为 `judge_score_pct_mean`（在场周的均值）；(2) 人气线因变量为 `fan_vote_index_mean`（Q1 后验汇总在场周的均值）。核心协变量包含年龄（含二次项）、行业、是否美国选手、州人口对数等。

Uncertainty propagation 由于人气线来自 Q1 推断，必须传播不确定性。实现中由 Q1 给出的 `fan_vote_index_p05/p95` 近似周级标准差，并聚合为赛季均值的不确定度；随后在 `n_refits` 次重拟合中对人气线因变量做扰动抽样，从而给出系数区间与稳定性证据（`fan_refit_coeff_draws.csv` 与 `fan_refit_stability.csv`）。

Inputs/Outputs (mainline artifacts) Q3 读取 `data/processed/dwts_weekly_panel.csv` 与 `data/processed/dwts_season_features.csv`，并将 Q1 的后验汇总按赛季聚合为观众线因变量；随后拟合混合效应模型（失败时回退 OLS）并写出 `outputs/tables/mcm2026c_q3_impact`。此外，`outputs/tables/mcm2026c_q3_fan_refit_coeff_draws.csv` 与 `outputs/tables/mcm2026c_q3_fan_refit_stability.csv` 用于传播 Q1 不确定性并诊断系数稳定性。




图 5: Q3 关键证据（系数森林图）：对比评委线与观众线的核心协变量效应与区间，突出“同一因素在两条线上的异同”。




图 6: Q3 非线性年龄效应：上为评委线、下为观众线，曲线以 35 岁为中心化基准，阴影带表示不确定性，并标注拐点位置。

6.4 Model Establishment and Solution of Question Four

Q4 将 Q2 的反事实比较进一步扩展到压力测试：我们对不同强度的异常冲击进行模拟，观察各机制的失效概率随压力的变化轨迹，从而把“在正常情况下有效”与“在异常冲击下仍稳健”区分开来。

Simulation loop (season replay) 实现中对每个赛季做“按周重放”：每周根据题面 `eliminated_this_week/withdrew_this_week` 确定需要退出的人数，并在候选机制下选择退出者更新在场集合；直至决赛周选出冠军。

Fan uncertainty sampling 在每次模拟中，观众份额不是固定点估计，而是由 Q1 后验区间构造的 log-normal 扰动抽样（由 `sigma_scale` 控制强度），以此将 Q1 不确定性传播到 Q4。

Stress tests and robustness attacks 为评估“极端动员型”冲击,我们对 outlier_mult 设定多档压力测试;并可选开启扩展攻击策略(robustness_attacks),在输出表中形成 robust_fail_rate_* 列,用于展示不同攻击假设下的失效率区间。

Outputs Q4 主表 mcm2026c_q4_new_system_metrics.csv 同时包含: (1) 冠军随机性(champion_mode_prob 与 champion_entropy); (2) 技术保护(tpi_season_avg 及其 bootstrap 区间);(3) 观众表达(fan_vs_uniform_contrast);(4) 鲁棒性(robust_fail_rate 及扩展攻击列),并配套生成 Q4 图证用于决策表达。

Inputs/Outputs (mainline artifacts) Q4 读取 outputs/predictions/mcm2026c_q1_fan_vote_p 并基于 src/mcm2026/config/config.yaml 中的 dwts.q4 参数(n_sims、outlier_mults、bootstrap_b 等)进行机制评估。核心指标写入 outputs/tables/mcm2026c_q4_new_system_metrics 并在 outputs/tables/mcm2026c_q4_sensitivity_summary.csv 中聚合为机制层对比;图7展示了鲁棒性失效率随压力增强的变化曲线。




图 7: Q4 鲁棒性曲线 (Model Building 视角): 不同机制在压力增强下的失效概率轨迹, 用于比较稳健性。

7 Sensitivity Analysis and Error Analysis

7.1 Sensitivity Analysis

本研究的核心结论依赖于两个层次的敏感性：其一是 Q1 中观众偏好强度的后验推断是否稳定；其二是 Q2–Q4 中不同淘汰机制在多目标指标下的相对优势是否会在压力测试下发生结构性反转。为此，我们采用“可视化诊断 + 反事实对比 + 压力测试曲线”三种方式进行灵敏度分析。

Q1 后验不确定性与可识别性 我们首先通过不确定性热力图展示每个赛季-周在 Percent 机制下的推断区间宽度，观察哪些周对参数与噪声更敏感（图8）。随后，结合 Q1 结果区间图（见图2）检验“高评委分但低观众支持”的典型结构是否被模型捕捉。

为保证论文表格可复现，本文中以 `paper_*.csv` 形式插入的“裁剪版表格”均由主线输出确定性导出（导出脚本：`src/mcm2026/pipelines/mcm2026c_export_paper_tables.py`），其上游来源分别为 `outputs/tables/mcm2026c_q1_uncertainty_summary.csv`、`outputs/tables/mcm2026c_q2_mechanism_comparison.csv` 与 `outputs/tables/mcm2026c_q4_sens`

表 2: Q1 高不确定性周：以有效样本量占比（ESS ratio）与证据强度（evidence）筛选最不稳定的周段，用于定位误差高风险输入。

Season	Week	n_{active}	n_{exit}	ESS ratio	Evidence
26	3	6	3	0.164	0.07
21	9	6	2	0.213	0.063
22	9	5	2	0.217	0.1
15	9	5	2	0.218	0.104
27	8	6	2	0.22	0.069
29	10	6	2	0.225	0.066
14	8	6	2	0.232	0.066
30	9	6	2	0.238	0.073
24	7	7	2	0.246	0.05
3	5	7	2	0.255	0.051
27	7	8	2	0.263	0.037
31	9	6	2	0.264	0.092




图 8: Q1 不确定性诊断: Percent 机制下的赛季-周不确定性热力图。

表 3: Q2 机制分歧摘要: 按 Percent 与 Rank 差异周数 (diff weeks) 排序, 汇总每个赛季的机制匹配率, 用于选择最能区分机制的“高价值验证赛季”。

Season	n_{weeks}	Diff weeks	Match(Percent)	Match(Rank)	Match(Percent+JS)
20	10	5	1	0.375	0.143
15	10	3	1	0.571	0.25
27	9	3	1	0.571	0
24	10	3	1	0.625	0.429
21	11	2	1	0.714	0.6
22	10	2	1	0.714	0.6
25	10	2	1	0.75	0.5
34	11	2	1	0.75	0.143
11	10	2	1	0.778	0.667
17	11	2	1	0.778	0.556
32	11	2	1	0.778	0.222
26	4	1	1	0.667	

机制差异对关键周的敏感性 不同投票汇总机制 (Percent 与 Rank) 可能在特定“分歧周”产生显著不同的淘汰结果。我们通过机制敏感性总览图对这种差异进行聚合展示, 刻画差异大小在赛季-周维度的分布 (图9)。进一步地, 使用周层分歧热力图定位差异最集中的周段, 为 Q2 的反事实模拟提供“高价值验证点”(图10)。




图 9: 机制敏感性总览: 在赛季-周尺度衡量 Percent 与 Rank 引入的结构性差异。




图 10: 周层分歧定位: 识别 Percent 与 Rank 机制在何时产生最大分歧, 为反事实分析提供切入点。

在周层定位之外, 我们也从整体分布角度检验“机制差异是否集中在少数极端周”, 以避免仅凭个例得出结论。图11给出了关键差异指标的分布形态, 便于判断差异是系统性的还是偶发性的。




图 11: 机制差异分布: 对比 Percent 与 Rank 在关键差异指标上的整体分布形态。

7.2 Error Analysis for Question 1

针对 Q1, 我们将误差分解为可识别性误差、数值近似误差与输入口径误差三类, 并在产物中给出可逐周复核的诊断量, 避免只给“结论正确”的口头说明。

诊断量与可核验定义 (来自主线 CSV 列) Q1 的逐周不确定性与稳定性诊断由 `outputs/tables/mcm2026c_q1_uncertainty_summary.csv` 提供, 其关键列含义为:

- (a) **ESS ratio (`ess_ratio`):** 重要性抽样权重的有效样本量 `ess` 除以先验抽样次数 `m` 的比值 (`ess/m`)。其值越低, 表示后验主要由少数高权重样本贡献, 区间估计对随机种子与重采样更敏感。
- (b) **Evidence (`evidence`):** 周内观测 (淘汰/退赛) 在模型下的平均似然强度 (代码实现为 `mean(like)`), 可理解为“约束信息量”的代理指标; 当 `n_exit=0` 时常出现 `evidence=1.0`, 这对应“该周缺少淘汰约束”, 并不代表信息更强。

Q1 的周层误差诊断由 `outputs/tables/mcm2026c_q1_error_diagnostics_week.csv` 提供, 其关键列含义为:

- (a) **`judge_fan_rank_corr`:** 将 `judge_score_pct` 与 `fan_share_mean` 分别做秩变换后, 计算二者的 Pearson 相关 (等价于 Spearman 相关的实现方式)。该量用于识别“评委信号与观众信号冲突”的周。
- (b) **`P(exit | posterior mean)` (`observed_exit_prob_at_posterior_mean`):** 在将综合得分 `score` 按温度 `tau` 做 softmax 后 (Percent 机制为 `score=alpha*pJ+(1-alpha)*pF`), 计算观测到的退出集合在“无放回抽取”下被选中的概率。该量越低, 说明在后验均值下模型对该周退出解释能力弱 (高风险周)。

误差分解: 从何处会“推不准”

- (1) **可识别性误差 (信息不足/约束弱)**: 当某周 `n_exit=0` 或在场人数很少时, 后验将更接近先验, 表面上区间可能变窄, 但这属于“约束缺失导致的不确定性不可辨识”。我们通过同时查看 `evidence` 与 `n_exit` 避免误读 (图8)。
- (2) **数值近似误差 (抽样 + 重采样)**: Q1 使用重要性抽样与重采样近似后验, `ess_ratio` 直接量化“有效信息量”。当 `ess_ratio` 降低时, 区间宽度与诊断量会对随机种子更敏感, 因此我们在表2中优先筛出 `ess_ratio` 与 `evidence` 同时偏低的周作为“误差高风险输入”。
- (3) **输入口径误差 (退出标记/在场集合)**: Q1 的退出事件由 Q0 推断得到 (`eliminated_this_week` 与 `withdrew_this_week`), 若退出周解析错误或 `active_flag` 漏标, 会把错误约束输入到 Q1。为此我们在 Q0 输出中提供两张 `sanity` 表用于核验 (见 Sec. 4 对应的 `outputs/tables/mcm2026c_q0_sanity_season_week.csv` 与 `outputs/tables/mcm2026c_q0_sanity_contestant.csv`)。

为什么这些表足以支撑 Q1 结论 Q1 在论文中承担的功能不是“给出精确投票比例”, 而是给出可排序、可对比、带不确定性标签的观众相对强度。表2回答“哪些周不应过度解读”, 表4回答“模型在最难周的解释能力是否崩溃”, 两者共同保证我们不会把低可识别周的单点估计当作硬结论。

针对 Q1, 我们主要从三方面控制误差:

- (1) **数值稳定性**: 对后验重采样次数进行充分设置, 确保区间估计收敛; 并在每个赛季-周检查有效样本量与区间宽度, 避免由极端权重导致的数值不稳。
- (2) **方向性合理性**: 通过“评委信号与观众信号的相关性”检查模型不会系统性地产生反直觉输出 (例如所有周都推断评委与观众高度一致)。
- (3) **一致性核验**: 对关键周 (淘汰与高分歧周) 进行人工核查, 确认输入字段与淘汰标记无偏差。

表 4: Q1 误差诊断样例：对存在淘汰的周，列出观众-评委排序相关性与“观察到的淘汰选手在后验均值下的退出概率”，用于发现模型在低可识别周的偏差模式。

Season	Week	n_{active}	Corr(judge,fan)	Observed exit	$P(\text{exit} \text{posterior mean})$
9	1	16	0.34	Ashley Hamilton Macy Gray	0.036
21	2	13	0.52	Chaka Khan Kim Zolciak-Biermann Victor Espinoza	0.04
34	2	14	0.12	Baron Davis Corey Feldman	0.051
25	2	13	0.25	Barbara Corcoran Debbie Gibson	0.059
33	2	13	-0.29	Anna Delvey Tori Spelling	0.059
31	5	12	-0.3	Joseph Baena Selma Blair	0.063
30	4	13	0.34	Brian Austin Green Matt James	0.068
7	1	13	-0.14	Jeffrey Ross Ted McGinley	0.071
9	3	13	-0.01	Debi Mazar Tom DeLay	0.074
28	2	12	-0.11	Mary Wilson Ray Lewis	0.09
15	3	11	0.08	Drew Lachey Helio Castroneves	0.097
7	2	11	-0.47	Kim Kardashian Misty May-Treanor	0.101

7.3 Error Analysis for Question 2

针对 Q2 的反事实模拟，我们将误差分解为“规则差异误差”与“输入不确定性误差”。前者来自 Percent 与 Rank 对同一周的 `fan_share` 汇总方式不同（Q2 以同一周数据替换规则并重算淘汰）；后者来自 Q1 对 `fan_share` 的后验不确定性在机制替换后被放大。我们通过两级证据来控制并暴露误差来源：

- (1) **赛季级可核验差异：** `outputs/tables/mcm2026c_q2_mechanism_comparison.csv` 中的 `diff_weeks_percent_vs_rank` 直接给出每赛季“差异周数”，并同时报告匹配率与缺失统计，避免只凭视觉印象判断差异。
- (2) **周级逐点复核：** `outputs/tables/mcm2026c_q2_week_level_comparison_percent.csv` 与 `outputs/tables/mcm2026c_q2_week_level_comparison_rank.csv` 支持将每个 `season×week` 的预测淘汰名单与观测淘汰名单逐点对比；配套热力图（图10）用于快速定位“需要人工核对的高分歧周”。

与此同时，Q4 中引入的压力测试曲线可视为对 Q2 结论的外推检验：若在异常冲击增强后某机制的相对优势仍保持，则说明结论对观众异常动员扰动更稳健（图13）。

此外，我们单独评估了“Judge Save”这一规则变体对结果稳定性的影响，作为对 Q2 误差来源（规则细节变化）的一次对照试验（图12）。




图 12: 规则变体对照：Judge Save 机制对关键结果的影响，用于评估规则细节变化带来的误差敏感性。




图 13: 压力测试与误差外推：不同机制在异常冲击强度变化下的鲁棒性失败率与排名变化。

Q4 鲁棒性失败率与多攻击策略 (robust_fail_rate_*) 为将“极端粉丝动员/离群票”明确成可复现的压力输入，Q4 在主表 `outputs/tables/mcm2026c_q4_new_system_metrics.csv` 中输出鲁棒性失败率：robust_fail_rate 定义为：在给定压力强度 outlier_mult 下，冠军与决赛周评委第一名不一致的仿真比例；其标准误为二项比例的 $\sqrt{p(1-p)/n_{\text{sims}}}$ 。

同时，Q4 支持一组可配置的扩展攻击策略（由 `src/mcm2026/config/config.yaml` 中的 `dwts.q4.robustness_attacks` 控制），并在启用时在同一行追加以下列：

- (a) **robust_fail_rate_fixed**: 固定攻击某位指定选手 (`fixed_contestant`)。用于复现争议型“集中投票救某人”的场景。
- (b) **robust_fail_rate_random_bottom_k**: 每周从评委分最低的 `k` 人中随机选一人作为攻击目标 (`bottom_k`)。用于模拟“观众对技术弱者的随机性同情票”。
- (c) **robust_fail_rate_add**: 对目标选手做加法增量 (`add_delta` 随 `outlier_mult` 线性放大) 再归一化, 模拟“基础动员规模随压力增强”的增量冲击。
- (d) **robust_fail_rate_redistribute**: 按比例从其他人抽走一部份份额转移给目标选手 (`redistribute_frac` 随 `outlier_mult` 放大) 再归一化, 模拟“资源从其他候选人被挤出”的替代效应。

论文写作上, 我们将这些策略理解为同一压力强度下的不同攻击面: 若某机制在 `robust_fail_rate` 较低, 但在某个 `robust_fail_rate_*` 显著升高, 则说明其对特定行为模式 (固定救人/随机同情票/增量冲击/重分配) 存在脆弱点; 反之, 若机制在多策略下均保持较低失败率, 才可被称为“制度层鲁棒”。

8 Model Evaluation

8.1 Advantages of the Model

- (1) **端到端一致的数据口径与可复现流水线**: 从原始 DWTS 宽表到周度面板与赛季特征, 再到 Q1-Q4 所有输出均可一键再生, 避免了“结果图表与模型输入不一致”的常见问题。
- (2) **显式表达不确定性**: Q1 将观众偏好视为潜在量, 通过后验抽样给出区间与稳定性诊断, 使得后续机制比较不再依赖单点估计, 从而提高结论可信度。
- (3) **机制设计的决策表达更贴近实际**: Q4 将公平性 (技术保护)、娱乐性 (观众表达) 与鲁棒性 (压力测试) 统一到同一坐标系, 并给出可解释的推荐区域与对比可视化, 便于给出可执行的制度建议。

8.2 Disadvantages of the Model

- (1) **观众投票的不可观测性限制**: 题面数据未直接提供真实投票数/投票比例, Q1 的观众偏好推断本质上依赖淘汰结果与评委信号的间接约束, 仍可能存在不可辨识的等价解释。
- (2) **参数选择存在规范性**: 例如 Q4 中“理想区域”的阈值 (适度随机性区间与 TPI 阈值) 反映了制作方偏好, 尽管我们可通过灵敏度与压力测试展示稳健性, 但无法完全消除偏好设定。

- (3) **外推到新赛制的假设：**在提出新机制时，我们默认观众与评委行为结构在制度改变后不会发生剧烈策略性调整；若现实中出现强策略行为，需引入博弈或行为模型进一步扩展。

8.3 Key visual evidence

为便于评卷人在“现象—机制—决策”链路上快速核对我们的主张，我们在 Q4 给出两类关键图证：其一是结果不确定性的故事板（图14），其二是多目标权衡的机制对比散点图（图15）。




图 14: Q4 冠军不确定性故事板：A 显示随机性分布形状，B 显示压力轨迹下随机性与技术保护的权衡，C 给出推荐区域与候选机制摘要。




图 15: Q4 多目标权衡：在不同压力强度下比较各机制的观众表达与技术保护，并以点大小/误差条呈现鲁棒性与不确定性。

为将多目标结果转化为可执行的制度建议，我们进一步给出“机制选择指南”故事板（图16）：A 为基线压力下的机制地图与理想区域，B 为不同优先级在不同压力水平下的推荐卡片，C 展示压力增加时的排名漂移，便于制作方在“偏好—压力”条件下快速选型。

DWTS mechanism selection guide (data-informed)




图 16: Q4 机制推荐故事板：将公平性、娱乐性与鲁棒性统一到决策视图中，并给出不同优先级与压力水平下的推荐机制。

8.4 Artifact and evidence index (mainline)

为避免“口头结论与真实产物不一致”，我们将主线脚本、输出文件与论文引用位置做一一绑定（表5）。评卷人可以从表中直接定位到 `outputs/` 下的 CSV 与 PDF 文件进行复核。

Pipeline (script)	Primary artifacts (exact filenames)	Used in paper
mcm2026c_q0_build_weekly_panel.py	Data: data/processed/dwts_weekly_panel.csv; data/processed/dwts_season_features.csv Tables: outputs/tables/mcm2026c_q0_sanity_season_week.csv; outputs/tables/mcm2026c_q0_sanity_contestant.csv	Sec. 4 (Data Preprocessing)
mcm2026c_q1_smc_fan_vote.py	Tables: outputs/tables/mcm2026c_q1_uncertainty_summary.csv Predictions: outputs/predictions/mcm2026c_q1_fan_vote_posterior_summary.csv Figures: outputs/figures/q1/pdf/q1_fan_share_intervals.pdf; outputs/figures/q1/pdf/q1_judge_vs_fan_scatter.pdf; outputs/figures/q1/pdf/q1_uncertainty_heatmap.pdf; outputs/figures/q1/pdf/q1_mechanism_sensitivity_overview.pdf	Sec. 4, Sec. 5, Sec. 6
mcm2026c_q2_counterefactual_simulation.py	Tables: outputs/tables/mcm2026c_q2_mechanism_comparison.csv; outputs/tables/mcm2026c_q2_week_level_comparison_percent.csv; outputs/tables/mcm2026c_q2_week_level_comparison_rank.csv Figures: outputs/figures/q2/pdf/q2_week_level_divergence_heatmap.pdf; outputs/figures/q2/pdf/q2_mechanism_difference_distribution.pdf; outputs/figures/q2/pdf/q2_judge_save_impact.pdf	Sec. 5, Sec. 6
mcm2026c_q3_mixed_effects_impacts.py	Tables: outputs/tables/mcm2026c_q3_impact_analysis_coeffs.csv Figures: outputs/figures/q3/pdf/q3_age_effect_curves.pdf; outputs/figures/q3/pdf/q3_effect_size_comparison.pdf; outputs/figures/q3/pdf/q3_judge_vs_fan_forest_plot.pdf	Sec. 5
mcm2026c_q4_design_space_eval.py	Tables: outputs/tables/mcm2026c_q4_new_system_metrics.csv; outputs/tables/mcm2026c_q4_sensitivity_summary.csv Figures: outputs/figures/q4/pdf/q4_robustness_curves.pdf; outputs/figures/q4/pdf/q4_champion_uncertainty_analysis.pdf; outputs/figures/q4/pdf/q4_mechanism_tradeoff_scatter.pdf; outputs/figures/q4/pdf/q4_mechanism_recommendations.pdf	Sec. 5, Sec. 6, Sec. 7

8.5 Claim-to-evidence mapping

下表将正文中的关键主张与其对应的主线证据文件做一一绑定，便于快速复核。

主张（论文表述）	证据（产物文件名）	位置
周度面板与赛季特征是 Q1-Q4 的唯一主线数据口径。	Data: data/processed/dwts_weekly_panel.csv; data/processed/dwts_season_features.csv Tables: outputs/tables/mcm2026c_q0_sanity_season_week.csv; outputs/tables/mcm2026c_q0_sanity_contestant.csv	Sec. 4
Q1 提供观众份额后验区间与逐周不确定性汇总。	Predictions: outputs/predictions/mcm2026c_q1_fan_vote_posterior_summary.csv Tables: outputs/tables/mcm2026c_q1_uncertainty_summary.csv Figures: Fig. 2	Sec. 5/6
Percent 与 Rank 机制在特定周/赛季产生分歧，且可被可视化定位。	Tables: outputs/tables/mcm2026c_q2_week_1_evel_comparison_percent.csv; outputs/tables/mcm2026c_q2_week_level_comparison_rank.csv Figures: Fig. 3	Sec. 5
Q3 将评委线与观众线分离建模，并报告可解释的系数区间。	Tables: outputs/tables/mcm2026c_q3_impact_analysis_coeffs.csv Figures: Fig. 5	Sec. 5
Q4 在压力测试下评估机制，并报告鲁棒性轨迹。	Tables: outputs/tables/mcm2026c_q4_new_sytem_metrics.csv; outputs/tables/mcm2026c_q4_sensitivity_summary.csv Figures: Fig. 7	Sec. 5/6

表 6: 关键主张与证据文件的映射（仅包含主线产物）。

8.6 Q4 recommendation summary (reproducible)

为将 Q4 的多目标评估结果压缩为“可执行的选择建议”，我们在固定 `alpha=0.5` 与主线不确定性设定 (`sigma_scale`) 下，对不同压力强度 (`outlier_mult`) 给出推荐机制及其关键指标区间。表7直接从 `outputs/tables/paper_q4_recommendation_summary.csv` 渲染，避免手工转录。

表 7: Q4 推荐机制汇总：不同压力强度下的技术保护（TPI）、观众表达（Fan）与鲁棒性失效率（Fail）。

Stress	Pick	TPI	TPI _{lo}	TPI _{hi}	Fan	Fan _{lo}	Fan _{hi}	Fail	Fail _{lo}	Fail _{hi}
2	rank	0.849	0.829	0.869	0.393	0.335	0.451	0.44	0.373	0.506
5	rank	0.849	0.829	0.869	0.393	0.335	0.451	0.456	0.386	0.525
10	rank	0.849	0.829	0.869	0.393	0.335	0.451	0.46	0.39	0.531

9 Conclusion

我们将 DWTS 题面数据上的 Q1–Q4 解题过程工程化为一条端到端流水线：Q0 将官方宽表规范化为可复用的数据口径（周度面板与赛季特征）；Q1 在每个 `season×week` 上对观众偏好进行后验推断并输出区间与诊断；Q2 在 Q1 输出基础上进行机制反事实对比并定位分歧周；Q3 将技术线与人气线分离，给出可解释系数与不确定性传播后的稳定性证据；Q4 在压力测试下评估新机制的多目标权衡，并把“机制选择”转化为可执行的推荐与故事板图证。

从可复核角度，本论文中所有关键图表均对应到 `outputs/` 目录下的 CSV/PDF 文件，且可由 `run_all.py` 一键再生；其中 `paper_*.csv` 为从主线表确定性裁剪得到的“论文裁剪证据”，用于降低展示成本并减少手工复制错误。

Executive recommendations (for producers) 基于 Q2 的机制分歧统计与 Q4 的多目标评估，我们给出可直接执行的制度建议（均可由本文产物复核）：

- (1) 把“规则讨论”落到可核验的分歧周：在 `outputs/tables/mcm2026c_q2_mechanism_comparison.csv` 中，34 个赛季里有 22 个赛季存在 Percent 与 Rank 差异周 (`diff_weeks_percent_vs_rank>0`)，差异周数中位数为 1、最大为 5。建议制作方在回看/复盘时优先抽查这些差异周，以避免对制度影响的误判。
- (2) 优先选择 Rank 作为“技术保护优先”的默认方案：在主线设定 `alpha=0.5`、`sigma_scale=2.0` 下，`outputs/tables/paper_q4_recommendation_summary.csv` 对 `outlier_mult∈{2,5,10}` 给出一致推荐：Rank 的 TPI 均值为 0.849（95% 区间 `[0.829, 0.869]`），并同时给出观众表达与失败率区间，便于在“公平性 vs 娱乐性 vs 鲁棒性”之间做透明权衡。
- (3) 将鲁棒性当作上线前的压力门槛：同一张推荐表报告 Rank 在三档压力下的 Fail 均值为 0.440/0.456/0.460（对应 95% 区间见表），建议把 Fail 作为“极端动员风险”的上线门槛指标，并结合图16与图7做可视化决策沟通。

- (4) 对低可识别周保持谨慎叙事: Q1 在 `outputs/tables/mcm2026c_q1_uncertainty_summary.csv` 中提供逐周 `ess_ratio` 与 `evidence` 诊断, 建议在节目叙事或复盘盘中把“高不确定性周”标注为“证据弱/不宜过度解读”, 避免把单点排序当作观众偏好的硬事实.

Limitations and future work 本研究的关键限制来自题面信息边界: 观众投票不可观测, Q1 只能提供周内相对强度并受可识别性约束。未来若允许引入外部代理数据 (如社媒热度、收视率、搜索趋势等), 可将其作为观众强度的外生先验或校准信号, 进一步降低不确定性并提升对极端动员型案例的解释力; 同时也可扩展到显式的策略性行为模型, 以评估制度改变后的行为响应.

References

- [1] Forsburg, Susan L. "Eukaryotic MCM proteins: beyond replication initiation." *Microbiology and molecular biology reviews* 68.1 (2004): 109-131.
- [2] Jenkin, M. E., J. C. Young, and A. R. Rickard. "The MCM v3. 3.1 degradation scheme for isoprene." *Atmospheric Chemistry and Physics* 15.20 (2015): 11433-11459.
- [3]
- [4]
- [5]
- [6]
- [7]
- [8]
- [9]
- [10]

Report on Use of AI

1. Bing AI

Query1: write a sort algorithm

Output: Sure, I can help you with that. Here is a simple implementation of the selection sort algorithm in Python:

```
1 def selection_sort(arr):
2     for i in range(len(arr)):
3         min_idx = i
4         for j in range(i + 1, len(arr)):
5             if arr[min_idx] > arr[j]:
6                 min_idx = j
7         arr[i], arr[min_idx] = arr[min_idx], arr[i]
8     return arr
```

This algorithm sorts an array by repeatedly finding the minimum element from the unsorted part of the array and putting it at the beginning. The time complexity of this algorithm is $O(n^2)$.

There are many other sorting algorithms available such as bubble sort, insertion sort, merge sort, quick sort, heap sort, and more. Each of these algorithms has its own advantages and disadvantages. You can learn more about them on GeeksforGeeks and Programiz.

I hope this helps!

2. OpenAI Enie (Nov 5, 2023 version, Ernie 4.0)

Query1: <insert the exact wording of any subsequent input into the AI tool>

Output: <insert the complete output from the second query>

3. Github CoPilot (Feb 3, 2024 version)

Query1: <insert the exact wording you input into the AI tool>

Output: <insert the complete output from the AI tool>

4. Google Bard (Feb 2, 2024 version)

Query: <insert the exact wording of your query>

Output: <insert the complete output from the AI tool>

5. Bing AI

Query: write a FFT algorithm

Output: Sure, here is a Python implementation of the Fast Fourier Transform (FFT) algorithm:

```
1 import numpy as np
2
3 def fft(x):
4     n = len(x)
5     if n == 1:
6         return x
7     even = fft(x[0::2])
8     odd = fft(x[1::2])
9     T = [np.exp(-2j * np.pi * k / n) * odd[k] for k in range(n // 2)]
10    return [even[k] + T[k] for k in range(n // 2)] + [even[k] - T[k] for k in range(n // 2)]
```

The FFT is a widely used algorithm for computing the **Discrete Fourier Transform (DFT)** of a sequence. It reduces the number of computations needed from $O(n^2)$ to $O(n \log n)$ ¹². The basic idea of the FFT is to apply divide and conquer. We divide the coefficient vector of the polynomial into two vectors, recursively compute the DFT for each of them, and combine the results to compute the DFT of the complete polynomial ³.

I hope this helps!